

Recomendación de anuncios

Jorge Almonacid, Rubén Genillo, Humberto Pérez de la Blanca, Cristina Suárez
Universidad San Pablo CEU

Indice

0.1	Brainstorming	2
0.2	Objetivo	2
0.3	Tareas	3
0.4	Diagramas	4
0.5	Proyecto	5
0.6	Conclusiones	9
0.7	Bibliografía:	11

0.1 Brainstorming

Durante el brainstorming, se exploraron diversas áreas de interés, desde la seguridad informática con el análisis de correos maliciosos y el desarrollo de un detector de malware, hasta la aplicación de la teoría de juegos para identificar posibles trampas, lo que representa un enfoque innovador con amplias implicaciones. Además, se abordó el campo de la inteligencia artificial con la creación de un modelo de generación de texto, lo que refleja un interés en tecnologías avanzadas y su impacto potencial.

Se seleccionó una idea centrada en el ámbito del análisis de datos en redes sociales para la recomendación de anuncios. Esta propuesta demuestra una comprensión perspicaz del papel cada vez más relevante que desempeñan las opiniones y tendencias en línea en el mundo del marketing digital.

0.1.0.1 Necesidades:

Al haber seleccionado la idea centrada en el análisis de datos en redes sociales para la recomendación de anuncios, se pone de manifiesto la importancia de estar actualizados, ser precisos y comprender las respuestas de los clientes. Estas necesidades reflejan la relevancia de mantenerse al tanto de las tendencias cambiantes en línea, la precisión en la interpretación de datos y la comprensión profunda de las interacciones de los clientes en entornos digitales. Este enfoque resalta la importancia estratégica del marketing en un mundo cada vez más impulsado por la información y las interacciones en línea.

0.2 Objetivo

El objetivo de la extracción de datos y opiniones en redes sociales de usuarios para la recomendación de anuncios se fundamenta en la necesidad de acceder a información pública, en tiempo real y constantemente actualizada. Este enfoque estratégico busca aprovechar la riqueza de datos disponibles en entornos digitales públicos, garantizar la relevancia y actualidad de la información recopilada, y capturar las tendencias y opiniones más recientes. Al hacerlo, se busca informar decisiones de marketing con datos dinámicos y significativos, alineados con las demandas cambiantes del mercado y las interacciones de los usuarios en línea.

Además, este enfoque puede tener usos alternativos significativos que van más allá de la recomendación de anuncios. Por ejemplo, la extracción de datos y opiniones en redes sociales puede ser invaluable para la investigación de clientes, permitiendo una comprensión más profunda de sus necesidades, preferencias y comportamientos en línea. Asimismo, la identificación de *Brand Ambassadors*, es decir, usuarios influyentes que puedan promover de manera auténtica una marca, es otro beneficio clave de esta estrategia. Además, el manejo de reputación en línea se ve reforzado por la capacidad de monitorear y responder de manera proactiva a las interacciones en redes sociales, lo que puede impactar positivamente la percepción pública de una empresa o producto. Estos son solo algunos ejemplos de cómo este enfoque puede ser aprovechado para una variedad de aplicaciones estratégicas más allá de la publicidad y recomendaciones comerciales.

0.3 Tareas

La tarea se puede dividir en los siguientes temas:

0.3.0.1 Extracción de Datos:

En esta fase, se enfocará en la extracción de datos clave de la plataforma Twitter. Se buscará obtener información pública de los usuarios, como nombres, biografías, publicaciones, día y hora de publicación, comentarios, interacciones como me gusta, seguidores, seguidos y hashtags utilizados. Esta información será recopilada a través de una API que permitirá acceder a estos datos de manera estructurada. Además, se profundizará en la obtención de información personal más detallada, como edad, género, localización, ocupación e intereses de los usuarios para enriquecer el análisis.

0.3.0.2 Filtrar posts relevantes:

Una vez recopilados los datos, el siguiente paso será filtrar y clasificar los posts relevantes. Para lograr esto, se implementará un análisis de temas avanzado. Se utilizarán algoritmos especializados como el Análisis Semántico Latente (LSA) y la Asignación Latente de Dirichlet (LDA) para identificar patrones y agrupar los posts según los temas principales que abordan. Este proceso permitirá segmentar la información de manera efectiva y comprender mejor las discusiones que tienen lugar en la plataforma.

0.3.0.3 Análisis de sentimiento:

Otro aspecto fundamental de esta tarea es el análisis de sentimiento. Aquí se enfocará en determinar la polaridad de las opiniones expresadas en los posts recopilados. Para ello, se emplearán lexicons de sentimiento que ayudarán a clasificar las opiniones como positivas, negativas o neutras. Además, se explorará un método alternativo que involucra el uso de LMQL o langchain con Large Language Models para mejorar la precisión y profundidad del análisis de sentimiento.

Se estudiarán detenidamente los datos obtenidos de Twitter para llevar a cabo estas tareas con rigor y obtener información significativa que puedan impulsar estrategias efectivas en marketing digital y toma de decisiones empresariales.

0.3.0.4 Topic modeling:

Finalmente aplicamos el topic modeling para categorizar automáticamente los temas principales de los datos extraídos previamente, los cuales se guardarán en una base de datos. Una vez tenemos los temas, se procederá a la asignación de anuncios, los cuales serán clasificados mediante un resumen por el mismo algoritmo de topic modeling y serán asignados a la gente con las que coincidan los temas.

0.4 Diagramas

Tuvimos que realizar 2 diagramas, por un lado el diagrama de desarrollo, que muestra que actividades se van a realizar en el proyecto. Y por otro lado el diagrama de Gantt, que se encarga de distribuir las tareas y actividades en una línea temporal.



Figura 1: Diagrama de desarrollo

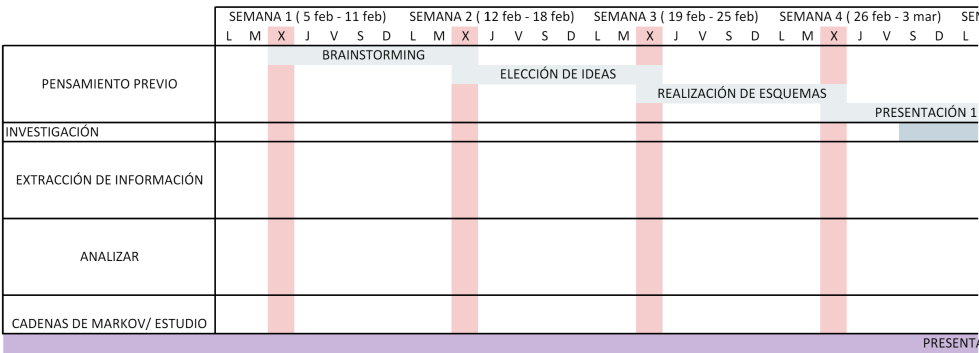


Figura 2: Gant parte 1




Figura 3: Gant parte 2




Figura 4: Gantt parte 3

0.5 Proyecto

0.5.0.1 Extracción de datos

Durante la fase inicial de nuestro proyecto, nos enfrentamos a un desafío inesperado al intentar extraer datos de la plataforma Twitter utilizando su API. Nos dimos cuenta de que las configuraciones de privacidad habían experimentado cambios significativos, lo que nos impedía acceder a la información de manera directa como habíamos planeado inicialmente. Ante esta situación, adoptamos un enfoque alternativo y multidimensional para recopilar los datos requeridos. Por un lado, recurrimos a técnicas de web scraping, un método que implica la extracción de información directamente desde el código HTML de las páginas web relevantes. Este enfoque nos permitió obtener acceso a datos públicos disponibles en perfiles y publicaciones de Twitter, superando así las restricciones impuestas por la API. Por otro lado, empleamos una estrategia de “fuerza bruta” para recopilar datos de interés. A través de esta técnica, pudimos obtener información valiosa mediante la exploración exhaustiva y sistemática de diversas fuentes de datos disponibles públicamente. Además, es importante destacar que el web scraping, a pesar de sus beneficios, requiere una cuidadosa consideración ética y legal para garantizar el cumplimiento de las políticas y regulaciones vigentes. En resumen, nuestro enfoque combinado de web scraping y fuerza bruta nos permitió superar los obstáculos iniciales y obtener un conjunto integral de datos de Twitter, proporcionando así una base sólida para nuestro análisis y recomendaciones.

0.5.0.2 IA para análisis de sentimiento

El análisis de sentimiento implica la aplicación de técnicas avanzadas de inteligencia artificial para comprender la carga emocional de los mensajes expresados en las redes sociales.

El objetivo es determinar la polaridad de las opiniones y emociones de los textos, en nuestro caso empleamos *sentiment lexicons* basados en unigramas. Estos nos proporcionan las emociones y sentimientos asociados a las palabras individuales de un texto, tomando la emoción y sentimiento de un texto como el mayor sentimiento en este.

El uso de sentiment lexicons frente a otras técnicas de sentiment analysis ofrece la principal ventaja de ser más rápido, lo que es necesario para hacer el cálculo rápido de opinión de muchos individuos. Cabe aclarar que lo que conseguimos mediante los sentiments lexicons realmente son la positividad/neutralidad/negatividad de un texto, lo cual no siempre significa siempre sacar una opinión final, ya que si el texto habla muy negativamente sobre un tema y finalmente da un veredicto positivo se puede ver muy influenciado por una mayor cantidad de comentarios negativos y obtener que dicho texto habla negativamente. O como, por ejemplo, citar el comentario negativo de otra persona en un texto puede alterar negativamente el resultado positivo de un texto.

Iniciando nuestro análisis de sentimiento probamos distintos sentiment lexicons con opiniones polares, ya que existen otros como *ncr*¹ que son más concretos con el tipo de emoción, que fueron AFINN y Bing.

- AFINN asigna a ciertas palabras una puntuación de entre -5 y 5, siendo una puntuación negativa un sentimiento negativo y una puntuación positiva un sentimiento positivo.
- Bing directamente asigna el valor positivo o negativo a cada palabra.

A la hora de realizar test con texto extraído de twitter y comparar la positividad del texto en si surgían varios inconvenientes. El primero era que, por ejemplo, al analizar las opiniones en twitter del tráiler de la última película de Deadpool se penalizaban palabras como “Strange”, del nombre de un personaje de Marvel Dr.Strange, o “KILLED”, que se refiera a la expresión “they KILLED IT!!!” siendo esta positiva, lo cual se puede llegar a corregir (o incluso prever) al analizar las palabras con una emoción asignada que más aparecen e ignorarlas. Otro problema que surge es no capturar matices de su dominio como tomar en cuenta calificativos delante de una palabra como “no es bueno” o “no es cierto”, sarcasmo, o en general ideas que dependan del contexto. Dados los problemas surge una alternativa, VADER.

VADER (*Valence Aware Dictionary and sEntiment Reasoner*) es un sentiment lexicon basado en reglas gramaticales diseñado específicamente para analizar sentimientos expresados en redes sociales. VADER es capaz de analizar la positividad/neutralidad/negatividad un texto y dar un puntaje ente -1 y 1, y al estar basado en reglas gramaticales soluciona la mayoría de los principales problemas como la negación o el uso de exclamaciones, e incluso tomar la intensidad de palabras en mayúsculas o tomar sentimientos de emojis hechos con caracteres como “ :(”.

Para probar el rendimiento de VADER se utilizaron principalmente 2 datasets pertenecientes a kaggle, IMDB Dataset of 50K Movie Reviews² y Massive Rotten Tomatoes Movies & Reviews³. Ambos datasets de 50.000 y 1444963 filas respectivamente, contienen reviews de paginas como IMDB y Rotten Tomatoes junto con un sentimiento positivo y negativo asociado. Tras comparar los resultados se obtiene que VADER tuvo un 69,226% de aciertos con el dataset de IMDB y un 58,278% de aciertos, que no esta nada mal comparado con el resto de lexicons, sin embargo, la tolerancia entre falsos sentimientos positivos o falsos sentimientos negativos se pude ir ajustando dependiendo de las restricciones que tenga el análisis.

¹El NRC Emotion Lexicon es una lista de palabras en inglés y sus asociaciones con ocho emociones básicas (ira, miedo, anticipación, confianza, sorpresa, tristeza, alegría y disgusto) y dos sentimientos (negativo y positivo).

²Retrieved from <https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews>

³Retrieved from <https://www.kaggle.com/datasets/andrezaza/clapper-massive-rotten-tomatoes-movies-and-reviews>

0.5.0.3 IA para topic modeling (clasificar por temas)

El topic modeling es una técnica poderosa en el análisis de datos que permite identificar y categorizar automáticamente los temas principales discutidos en grandes conjuntos de documentos, como los mensajes de redes sociales. En este proyecto, se ha empleado inteligencia artificial para llevar a cabo esta tarea de manera eficiente y precisa. Además de utilizar algoritmos estándar como LSA (Análisis Semántico Latente) y LDA (Asignación Latente de Dirichlet), se exploran métodos emergentes que mejoren la segmentación y comprensión de las discusiones en la plataforma. Esto permitirá una visión más profunda de las tendencias y preocupaciones de los usuarios, proporcionando así una base sólida para la asignación estratégica de anuncios.

La *asignación latente de Dirichlet* es uno de los algoritmos más comunes para el modelado de temas. Sin entrar en los detalles matemáticos del modelo, podemos entender que está guiado por dos principios.

- Cada documento es una mezcla de temas. Visualizamos que cada documento puede contener palabras de varios temas en proporciones específicas. Por ejemplo, en un modelo de dos temas podríamos decir “El Documento 1 consiste en un 90% del tema A y un 10% del tema B, mientras que el Documento 2 está compuesto por un 30% del tema A y un 70% del tema B”.
- Cada tema es una mezcla de palabras. Por ejemplo, podríamos imaginar un modelo de dos temas sobre noticias estadounidenses, con un tema para “política” y otro para “entretenimiento”. Las palabras más comunes en el tema de política podrían ser “Presidente”, “Congreso” y “gobierno”, mientras que el tema de entretenimiento podría incluir palabras como “películas”, “televisión” y “actor”. Es importante destacar que las palabras pueden compartirse entre temas; una palabra como “presupuesto” podría aparecer igualmente en ambos.

LDA es un método matemático usado para estimar los documentos y los temas a la vez. Se trata de encontrar la mezcla de palabras que está asociado a cada tema, y la mezcla de temas que está asociado a cada documento

- Clasificación:

Para clasificar los temas usaremos python. Para ello usaremos la librería bertopic, que es una implementación de LDA que utiliza BERT, otro lenguaje de programación orientado al procesamiento natural del lenguaje, para la clasificación de los mensajes.

```
# Importamos las librerías necesarias
import pandas as pd
from bertopic import BERTopic

# Cargamos el modelo preentrenado
topic_model = BERTopic.load("MaartenGr/BERTopic_ArXiv")

# Leemos los datos
```

```

data = pd.read_csv("tweetspersonas.csv")

# Extraemos la información de los tweets y los usuarios
documents = data["full_text"].tolist()
users = data["user"].tolist()

# Ajustamos el modelo de temas a los documentos
num_topics = len(topic_model.get_topic_info())

# 2. Creamos el modelo de temas
topics, _ = topic_model.transform(documents)

# 3. Obtenemos la información de los temas
topic_info = topic_model.get_topic_info()

# Creamos una lista vacía para almacenar los resultados
result_list = []

# Iteramos sobre los tweets para asignar una etiqueta de tema a cada usuario
for user, topic in zip(users, topics):
    topic_label = topic_info.loc[topic_info['Topic'] == topic]['Name'].values[0]
    result_list.append({"user": user, "classification": topic_label})

# Convertimos la lista de resultados en un marco de datos de pandas
result_df = pd.DataFrame(result_list)

# Guardamos la clasificación de los usuarios en un archivo CSV
result_df.to_csv("user_classifications.csv", index=False)

# Imprimimos los primeros resultados
print(result_df.head())

```

Este código nos da como resultado un archivo CSV con la clasificación de los usuarios y los temas identificados en sus tweets. Esta información es valiosa para la segmentación de los usuarios y la asignación de anuncios personalizados.

En el contexto de nuestro proyecto, donde estamos analizando comentarios y usuarios de Twitter para recomendar anuncios, esta explicación sobre el modelado de temas es relevante por varias razones:

1. Identificación de temas relevantes: El modelado de temas nos ayuda a identificar automáticamente los temas principales discutidos en los comentarios de Twitter. Esto nos permite comprender mejor las preocupaciones y tendencias de los usuarios, lo cual es fundamental para adaptar nuestros anuncios de manera efectiva.

2. Segmentación de audiencia: Al entender los diferentes temas discutidos en los comentarios de Twitter, podemos segmentar mejor nuestra audiencia y dirigir nuestros anuncios de manera más precisa a grupos de usuarios con intereses específicos.
3. Optimización de contenido publicitario: Conocer los términos más comunes asociados con cada tema nos permite optimizar el contenido de nuestros anuncios para que sean más relevantes y atractivos para nuestra audiencia objetivo.

Una vez tenemos los temas identificados, podemos proceder a la asignación de anuncios.

0.5.0.4 Asignación de anuncios

La asignación de anuncios es un proceso crítico en el marketing digital, donde se seleccionan y presentan anuncios específicos a los usuarios en función de sus intereses y comportamientos en línea. En este proyecto, se implementará un sistema dinámico que adapte las recomendaciones de anuncios en tiempo real. Esto implica no solo considerar los datos demográficos y las preferencias individuales de los usuarios, sino también las tendencias emergentes identificadas a través del análisis de temas.

En el proceso de asignación de anuncios, se realizará una clasificación detallada de los usuarios en grupos específicos en función de los temas relevantes identificados. A estos grupos se les recomendarán anuncios relacionados con los temas específicos que se pueden ver en la base de datos y se analizarán utilizando técnicas de topic modeling los que mejor coincidan sus intereses y serán mostrados de manera personalizada. Esta estrategia garantiza una mayor relevancia y efectividad en la publicidad dirigida, maximizando así el retorno de la inversión y mejorando la experiencia del usuario en línea.

En un nivel más técnico, lo que se haría sería, dado un resumen del anuncio, clasificarlo mediante el mismo algoritmo y datos de entrenamiento y se guardarán en otra tabla de la base de datos, que estará estructurada de la siguiente manera:

Empresa anunciante | Anuncio | Resumen | Tema |

Una vez tenemos ambas tablas en la base de datos simplemente se hará un join entre ambas tablas y se mostrará el anuncio a los usuarios que coincidan con el tema del anuncio.

0.6 Conclusiones

El proyecto de análisis de datos en redes sociales para la recomendación de anuncios representa una amalgama de enfoques avanzados en inteligencia artificial y minería de datos aplicados al mundo del marketing digital. A través de técnicas como el análisis de sentimientos, el modelado de temas y la asignación dinámica de anuncios, se busca comprender y aprovechar la vasta cantidad de información generada en plataformas como Twitter para ofrecer recomendaciones de anuncios más relevantes y efectivas.

La capacidad de adaptación en tiempo real, la personalización de las recomendaciones y la comprensión profunda de los intereses individuales de los usuarios son pilares fundamentales de

este proyecto. Al emplear algoritmos avanzados y técnicas innovadoras, se busca no solo mejorar la efectividad de la publicidad en línea, sino también maximizar el retorno de la inversión y mejorar la experiencia del usuario.

Además, más allá de su aplicación directa en la publicidad digital, el proyecto abre nuevas oportunidades en áreas como la investigación de clientes, la gestión de la reputación en línea y la identificación de embajadores de marca. Esto destaca la versatilidad y el potencial estratégico de la minería de datos en redes sociales en el panorama empresarial actual.

En conclusión, el proyecto representa un paso significativo hacia una publicidad más inteligente y centrada en el usuario, aprovechando el vasto conjunto de datos disponibles en las redes sociales para informar decisiones comerciales más acertadas y estratégicas.

0.7 Bibliografía:

Kaggle. (n.d.). IMDb Dataset of 50K Movie Reviews. Retrieved from

<https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews>

Silge, J., & Robinson, D. (2017). Tidy Text Mining with R. O'Reilly Media.

Python Twitter. (n.d.). Getting Started. Retrieved from

https://python-twitter.readthedocs.io/en/latest/getting_started.html

Kaggle. (n.d.). Massive Rotten Tomatoes Movies & Reviews. Retrieved from

<https://www.kaggle.com/datasets/andrezaza/clapper-massive-rotten-tomatoes-movies-and-reviews>

Silge, J., & Robinson, D. (2017). Tidy Text Mining with R: Topic Modeling. Retrieved from

<https://www.tidytextmining.com/topicmodeling#alternative-lda-implementations>